

Statistique et Informatique (3I005)

2016-2017

Nicolas Baskiotis

Université Pierre et Marie Curie (UPMC)
Laboratoire d'Informatique de Paris 6 (LIP6)
<http://3I005.lip6.fr>

Cours 5 :

Variable aléatoire réelle continue
Théorème central limite
Applications

Plan

1 Variable aléatoire réelle et théorie de la mesure

2 Densité de probabilité

3 Lois usuelles

4 Théorème central limite

5 Applications

Mesures de probabilités sur \mathbb{R}

Motivation

Modéliser des résultats d'expériences aléatoires pouvant être des réels quelconques.

Par exemple : mesures de temps, de distances, d'espaces.

Exemple : Probabilité continue uniforme sur $[0, 1]$

On souhaite créer une mesure telle que chaque valeur est équiprobable.

Plus exactement : si $0 \leq a < b \leq 1$, $P([a, b]) = b - a$.

Plus généralement : on souhaite associer une mesure de probabilité aux *intervalles* de \mathbb{R} .

Quelques détails techniques...

Problème...

Selon la théorie usuelle (théorie des ensembles + axiome du choix) :
Il *n'existe pas* de fonction P telle que:

- 1 P est une mesure de probabilité,
- 2 P peut être calculée pour n'importe quel sous-ensemble de $[0, 1]$,
- 3 pour tout intervalle $[a, b] \subset [0, 1] : P([a, b]) = b - a$.

Autrement dit :

Il existe des ensembles de \mathbb{R} qui sont *non mesurables* : ensembles de Vitali par exemple.

Non-mesurable \sim contradiction s'ils l'étaient.

Mesures de probabilités : définition générale (1)

Tribu

Une tribu \mathcal{T} sur un ensemble Ω contient des sous-ensembles de Ω et vérifie:

- 1 $\Omega \in \mathcal{T}$,
- 2 si $E \in \mathcal{T}$, alors $\Omega \setminus E \in \mathcal{T}$,
- 3 si $(E_i)_{i \geq 1}$ est une suite d'ensembles appartenant à \mathcal{T} , alors $\bigcup_{i \geq 1} E_i \in \mathcal{T}$.

Note : l'ensemble des parties de Ω est une tribu.

Tribu de Borel

- La tribu de Borel sur \mathbb{R} , notée \mathcal{B} , est la plus petite tribu contenant tous les intervalles de \mathbb{R} , par exemple tous les ensembles du type : $\bigcup_{i \in \mathbb{N}} [a_i, b_i[$
- la tribu de Borel sur \mathbb{R}^n , notée \mathcal{B}_n est la plus petite tribu contenant les produits cartésiens de n ensembles de \mathcal{B} :

$$\{I_1 \times I_2 \times \dots \times I_n \mid \forall k, I_k \in \mathcal{B}\} \subset \mathcal{B}_n.$$

Les tribus de Borel contiennent les ensembles intéressants du point de vue des probabilités.

Mesures de probabilités : définition générale (2)

Espace mesurable

Un espace mesurable est un couple (Ω, \mathcal{T}) , où Ω est un ensemble et \mathcal{T} est une tribu sur Ω . (Note : $(\mathbb{R}, \mathcal{B})$ est donc un espace mesurable.)

Mesure de probabilité

Soit (Ω, \mathcal{T}) un espace mesurable.

Une mesure sur (Ω, \mathcal{T}) est une fonction $P : \mathcal{T} \rightarrow [0, +\infty[$ telle que :

- ❶ $P(\emptyset) = 0$,
- ❷ $\forall E \in \mathcal{T}, P(E) \geq 0$,
- ❸ si $(E_i)_{i \geq 1}$ sont deux à deux disjoints, et $\forall i, E_i \in \mathcal{T}$, alors

$$P\left(\bigcup_{i \geq 1} E_i\right) = \sum_{i \geq 1} P(E_i).$$

- ❹ Si de plus $P(\Omega) = 1$, alors P est une *mesure de probabilité*.

Cette définition généralise la définition du cours 1 en prenant $\mathcal{P}(\Omega)$ comme tribu sur Ω lorsque Ω est discret.

Mesure de Borel

Fait marquant 2

Il existe une mesure λ sur $(\mathbb{R}, \mathcal{B})$, appelée mesure de Borel, telle que :

pour tout intervalle $[a, b]$ de \mathbb{R} ($a \leq b$), $\lambda([a, b]) = b - a$.

La mesure de probabilité uniforme sur un intervalle $[A, B]$, $A < B$ est alors :

$$\forall I \in \mathcal{B}, P(I) = \frac{\lambda(I \cap [A, B])}{B - A}$$

Mesure de Borel sur \mathbb{R}^n

La mesure de Borel sur $(\mathbb{R}^n, \mathcal{B}_n)$, notée λ_n est définie par :

$$\forall I_1 \in \mathcal{B}, \dots, I_n \in \mathcal{B}, \lambda_n(I_1 \times \dots \times I_n) = \prod_{k=1}^n \lambda(I_k)$$

Par exemple : $\lambda_2([0, 1/2] \times [0, 1/2]) = 1/4$.

λ_2 correspond à l'aire d'une figure dans le plan, λ_3 au volume d'un objet dans l'espace à 3 dimensions.

Plan

1 Variable aléatoire réelle et théorie de la mesure

2 Densité de probabilité

3 Lois usuelles

4 Théorème central limite

5 Applications

Densité de probabilité

Définition

Une mesure de probabilité P sur $(\mathbb{R}^n, \mathcal{B}_n)$ admet une *fonction de densité* $p : \mathbb{R}^n \rightarrow \mathbb{R}$ si :

pour tout $I \subset \mathcal{B}_n$, $P(I) = \int_{x \in I} p(x) d\lambda_n(x)$

Exemples

- Si P est une mesure de probabilité sur $(\mathbb{R}, \mathcal{B})$ qui admet comme fonction de densité p , alors pour tout $a < b$, on a :

$$P([a, b]) = \int_a^b p(x) dx \quad (\text{avec les notations usuelles de l'intégrale sur } \mathbb{R}).$$

- La loi uniforme sur $[a, b]$ admet comme fonction de densité :

$$p(x) = \begin{cases} \frac{1}{b-a} & \text{si } x \in [a, b] \\ 0 & \text{sinon} \end{cases},$$

- une v.a. réelle à valeurs dans un ensemble discret n'a pas de fonction de densité.

Variables aléatoires à valeurs réelles

Variable aléatoire réelle

Soit P est une mesure de probabilité sur (Ω, \mathcal{T}) .

Une variable aléatoire réelle est une fonction $X : \Omega \mapsto \mathbb{R}$ telle que :

$$\forall I \in \mathcal{B}, X^{-1}(I) \in \mathcal{T}$$

X induit une mesure de probabilité P_X sur $(\mathbb{R}, \mathcal{B})$ par :

$$P_X(I) = P(X \in I) = P(X^{-1}(I)).$$

Note : cette définition généralise notre définition de variable aléatoires à valeurs réelles sur des ensembles discrets.

Fonctions de répartition et de densité d'une v.a.r.

Fonction de répartition

Soit X une variable aléatoire réelle sur (Ω, \mathcal{T}, P) .

La fonction de répartition de X , notée F_X , est définie par :

$$F_X : \left(\begin{array}{cc} \mathbb{R} & \rightarrow [0, 1] \\ t & \mapsto P(X \leq t) \end{array} \right)$$

On a alors $P(a < X \leq b) = F_X(b) - F_X(a)$.


Fonction de densité

Une v.a. réelle X admet une *fonction de densité* p_X , si, pour tout $x \in \mathbb{R}$:

$$F_X(x) = \int_{-\infty}^x p_X(u) du.$$

- On a alors, pour $a < b$, $P(a < X \leq b) = \int_a^b p_X(u) du$.
- Si X est une v.a.r. telle que sa fonction de répartition est dérivable, alors $p_X = F'_X$ est une densité de X .

Fonctions de répartition et de densité d'une v.a.r.



Espérance et variance d'une v.a.r. continue

Définition et propriétés

- Soit X une v.a.r. sur espace probabilisé $(\mathbb{R}^n, \mathcal{B}_n, P)$ où P a une fonction de densité p . L'espérance de X est alors définie par :

$$\mathbb{E}(X) = \int_{\omega \in \Omega} X(\omega) p(\omega) d\lambda_n(\omega).$$

- Soit X , une v.a.r. de densité p_X . L'espérance de X est définie par :

$$\mathbb{E}(X) = \int_{-\infty}^{+\infty} u p_X(u) du.$$

- La variance de X est définie par : $V(X) = \mathbb{E}((X - \mathbb{E}(X))^2)$.

- Soit $f : \mathbb{R} \mapsto \mathbb{R}$. Alors : $\mathbb{E}(f(X)) = \int_{-\infty}^{+\infty} f(u) p_X(u) du$

Les résultats montrés pour les v.a.r. à valeurs discrètes restent vraies :

- Les propriétés de l'espérance et de la variance,
- les inégalités de Markov et Tchebychev, et la loi des grands nombres.

Application : Méthodes de Monte-Carlo

Types d'algorithmes probabilistes

- Algorithmes Las Vegas : renvoient toujours la réponse correcte, mais dans un temps variable,
- algorithmes de Monte-Carlo : les ressources sont limitées a priori, mais le résultat peut ne pas être exact.

Exemple : approximation de nombres réels

Principe de la méthode (exemples : approximation de $\ln 2$ et de π) :

- 1 écrire le nombre comme l'espérance d'une fonction d'une v.a.r. à densité,

$$\ln 2 = \int_0^1 \frac{1}{1+u} du, \quad \frac{\pi}{4} = \int_{u=0}^1 \int_{v=0}^1 I_{\{u^2+v^2 \leq 1\}} dudv$$

- 2 générer n valeurs selon la densité, calculer la fonction pour chaque valeur échantillonnée,
- 3 loi des grands nombres : la moyenne des n valeurs calculées tend vers le nombre qu'on souhaite calculer.

Plan

1 Variable aléatoire réelle et théorie de la mesure

2 Densité de probabilité

3 Lois usuelles

4 Théorème central limite

5 Applications

Loi exponentielle



Définition et propriétés

Une v.a.r. X suit une loi exponentielle de paramètre $\lambda > 0$ si elle admet comme densité de probabilité :

$$p_X(t) = \begin{cases} \lambda e^{-\lambda t} & \text{si } t \geq 0 \\ 0 & \text{sinon} \end{cases}.$$

On a alors :

- $\mathbb{E}(X) = \frac{1}{\lambda}$, $V(X) = \frac{1}{\lambda^2}$, $F_X(t) = P(X \leq t) = 1 - e^{-\lambda t}$.
- La loi exponentielle est l'analogue continu de la loi géométrique,
- elle représente le temps d'attente avant la réalisation d'un événement.





Loi normale

Définition et propriétés

Une v.a.r. X suit une loi normale (ou gaussienne) de paramètres μ et σ^2 si elle admet comme densité de probabilité :

$$p_X(t) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2\sigma^2}(x-\mu)^2}$$


- $\mathbb{E}(X) = \mu$, $V(X) = \sigma^2$ (σ est donc l'écart-type de X).
- Si $\mu = 0$, on parle de loi *centrée*.
- Si $\mu = 0$ et $\sigma = 1$ alors X suit une loi normale *centrée réduite*.



Loi normale (2)

Propriétés additionnelles

- Symétrie : $F_X(\mu + t) = 1 - F_X(\mu - t)$ ($\Leftrightarrow P(X \leq \mu - t) = P(X \geq \mu + t)$),
- Si X suit une loi normale de paramètres (μ, σ^2) , alors $Y = \alpha X + \beta$ suit une loi normale de paramètres $\alpha\mu + \beta$ et $\alpha^2\sigma^2$.
En particulier, $\frac{X-\mu}{\sigma}$ suit une loi normale centrée réduite.
- Si X et X' sont indépendantes et suivent respectivement une loi normale de paramètres (μ, σ^2) et (μ', σ'^2) , alors $X + X'$ suit une loi normale de paramètres $\mu + \mu'$ et $\sigma^2 + \sigma'^2$.



Plan

- 1 Variable aléatoire réelle et théorie de la mesure
- 2 Densité de probabilité
- 3 Loix usuelles
- 4 Théorème central limite**
- 5 Applications

Théorème central limite

Énoncé du théorème

Soit $(X_n)_{n \geq 1}$ une suite de v.a.r. indépendantes et identiquement distribuées, d'espérances et de variances finies.

Les X_n peuvent suivre n'importe quelle loi dès que ces deux conditions sont respectées.

On note $\mu = \mathbb{E}(X_n)$ et $\sigma = \sqrt{V(X_n)}$ l'espérance et l'écart-type de X_n .

- En notant $S_n = \sum_{k \leq n} X_k$, on a :

$\frac{S_n - n\mu}{\sigma\sqrt{n}}$ a une espérance de 0 et un écart-type de 1

- De plus, pour tout t :

$$\lim_{n \rightarrow \infty} P\left(\frac{S_n - n\mu}{\sigma\sqrt{n}} \leq t\right) = \Phi(t)$$

$$\text{où } \Phi(t) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^t e^{-\frac{1}{2}x^2} dx.$$

Φ est la fonction de répartition de la loi normale centrée réduite.

Théorème central limite

Énoncé du théorème

Soit $(X_n)_{n \geq 1}$ une suite de v.a.r. indépendantes et identiquement distribuées, d'espérances et de variances finies.

Les X_n peuvent suivre n'importe quelle loi dès que ces deux conditions sont respectées.

On note $\mu = \mathbb{E}(X_n)$ et $\sigma = \sqrt{V(X_n)}$ l'espérance et l'écart-type de X_n .

- En notant $S_n = \sum_{k \leq n} X_k$, on a :

$\frac{S_n - n\mu}{\sigma\sqrt{n}}$ a une espérance de 0 et un écart-type de 1

- De plus, pour tout t :

$$\lim_{n \rightarrow \infty} P\left(\frac{S_n - n\mu}{\sigma\sqrt{n}} \leq t\right) = \Phi(t)$$

$$\text{où } \Phi(t) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^t e^{-\frac{1}{2}x^2} dx.$$

Φ est la fonction de répartition de la loi normale centrée réduite.

Théorème central limite

interprétation

$\lim_{n \rightarrow \infty} P\left(\frac{S_n - n\mu}{\sigma\sqrt{n}} \leq t\right) = P(Y \leq t)$ où Y suit une loi normale centrée réduite.

Formulation alternative informelle :

lorsque n est grand : $P\left(\frac{S_n - n\mu}{\sigma\sqrt{n}} \leq t\right) \approx P(Y \leq t)$

ou encore (toujours lorsque n est grand) :

$$P(S_n \leq z) \approx P\left(Y \leq \frac{z - n\mu}{\sigma\sqrt{n}}\right)$$

Un exemple : les X_n sont des variables de Bernoulli de paramètre p

lorsque n est grand : $P(S_n \leq k) = \sum_{i=0}^k C_n^i p^i (1-p)^{n-i} \approx P\left(Y \leq \frac{k - np}{\sqrt{np(1-p)}}\right)$

Théorème central limite

interprétation

$\lim_{n \rightarrow \infty} P\left(\frac{S_n - n\mu}{\sigma\sqrt{n}} \leq t\right) = P(Y \leq t)$ où Y suit une loi normale centrée réduite.

Formulation alternative informelle :

lorsque n est grand : $P\left(\frac{S_n - n\mu}{\sigma\sqrt{n}} \leq t\right) \approx P(Y \leq t)$

ou encore (toujours lorsque n est grand) :

$$P(S_n \leq z) \approx P\left(Y \leq \frac{z - n\mu}{\sigma\sqrt{n}}\right)$$

Un exemple : les X_n sont des variables de Bernoulli de paramètre p

lorsque n est grand : $P(S_n \leq k) = \sum_{i=0}^k C_n^i p^i (1-p)^{n-i} \approx P\left(Y \leq \frac{k - np}{\sqrt{np(1-p)}}\right)$

Théorème central limite

interprétation

$\lim_{n \rightarrow \infty} P\left(\frac{S_n - n\mu}{\sigma\sqrt{n}} \leq t\right) = P(Y \leq t)$ où Y suit une loi normale centrée réduite.

Formulation alternative informelle :

lorsque n est grand : $P\left(\frac{S_n - n\mu}{\sigma\sqrt{n}} \leq t\right) \approx P(Y \leq t)$

ou encore (toujours lorsque n est grand) :

$$P(S_n \leq z) \approx P\left(Y \leq \frac{z - n\mu}{\sigma\sqrt{n}}\right)$$

Un exemple : les X_n sont des variables de Bernoulli de paramètre p

lorsque n est grand : $P(S_n \leq k) = \sum_{i=0}^k C_n^i p^i (1-p)^{n-i} \approx P\left(Y \leq \frac{k - np}{\sqrt{np(1-p)}}\right)$


Théorème central limite

Un exemple : les X_n sont des variables de Bernoulli de paramètre p

lorsque n est grand : $P(S_n \leq k) = \sum_{i=0}^k C_n^i p^i (1-p)^{n-i} \approx P\left(Y \leq \frac{k - np}{\sqrt{np(1-p)}}\right)$

En pratique :

une loi binomiale peut être approximée par une loi normale si
 $np \geq 10$ et $n(1-p) \geq 10$



TCL et loi des grands nombres

Soit $(X_n)_{n \geq 1}$ une suite de v.a.r. indépendantes et identiquement distribuées.
On note μ leur espérance et σ leur écart-type.
On note $S_n = \sum_{k \leq n} X_k$.

- Loi des grands nombres :

$$\forall t > 0, P\left(-t \leq \frac{S_n}{n} - \mu \leq t\right) \xrightarrow{n \rightarrow \infty} 1.$$

- Théorème central limite :

$$\forall t > 0, P\left(-\frac{\sigma t}{\sqrt{n}} \leq \frac{S_n}{n} - \mu \leq \frac{\sigma t}{\sqrt{n}}\right) \xrightarrow{n \rightarrow \infty} 2\Phi(t) - 1$$

Plan

- 1 Variable aléatoire réelle et théorie de la mesure
- 2 Densité de probabilité
- 3 Lois usuelles
- 4 Théorème central limite
- 5 Applications**


Intervalles de confiance

Définition

Soit X , une variable aléatoire réelle.

Un intervalle de confiance à $c\%$ pour un paramètre p est défini par deux fonctions u et v telles que:

$$P(u(X) < p < v(X)) \geq c/100$$



Intervalles de confiance

Exemple : I.C. pour l'espérance d'une loi normale

Soient X_1, \dots, X_n , n v.a.r. indépendantes et suivant une loi normale d'espérance μ et d'écart-type σ .

L'espérance μ est inconnue. On souhaite déterminer un intervalle de valeurs possibles pour μ , en supposant que σ est connue.

On note $X = \sum_{i=1}^n X_i$. $\frac{X - n\mu}{\sigma\sqrt{n}}$ suit une loi normale centrée réduite.

donc $\forall t, P\left(-t < \frac{X - n\mu}{\sigma\sqrt{n}} \leq t\right) = 2\Phi(t) - 1$. Donc, en fixant :

- t tel que $2\Phi(t) - 1 = c/100$ (par exemple : $t = 2$ pour 95%),
- $u(x) = \frac{x}{n} - \frac{\sigma t}{\sqrt{n}}$,
- $v(x) = \frac{x}{n} + \frac{\sigma t}{\sqrt{n}}$,

on a $P(u(X) < \mu < v(X)) \geq c/100$.

c'est un intervalle de confiance à $c\%$ pour le paramètre μ .

En théorie de l'information

Entropie : quantité d'information

- Je cherche à deviner un nombre entre 0 et 100 en posant des questions.
- quelle question m'apporte le plus d'information ?
 - ▶ le nombre est-il pair ?
 - ▶ le nombre finit-il par 12 ?
 - ▶ le nombre est-il supérieur à 50 ?
- Notion d'entropie : nombre minimum de question à poser pour trouver le nombre.

Définition

- Soit p une v.a. X à n valeurs distinctes i , chacune de probabilité p_i ,
- la probabilité de (x_1, \dots, x_t) tend vers $\prod_{k=1}^n p_k^{tp_k} = (\prod_{k=1}^n p_k^{p_k})^t$,
- l'entropie de p est $H(p) = -\sum_{i=1}^n p_i \log(p_i)$

Utilisations (entre autre)

- Codage de Huffman
- Arbres de décision

Classification et maximum de vraisemblance

Maximum de vraisemblance

Soit

- une famille de modèle $\mathcal{M} = \{\mathcal{M}_\theta\}$, paramétrée par un vecteur réel θ
- Vraisemblance d'un modèle pour des données X :
$$L(X; M_\theta) = p(X|M_\theta) = \prod_{x \in X} p(x|M_\theta)$$
- Maximum de vraisemblance : choix du modèle qui maximise la vraisemblance

Applications :

- classification d'images par histogramme
- classification de séquences : reconnaissance de la parole (HMM)
- infection et diffusion dans les graphes
- ...

Applications : dilemme de l'exploration/exploitation

Question : probleme du bandit-manchot

- soit K machines à sous disponible, toutes différentes,
- connaissant le résultat de mes n dernières tentatives,
- quelle machine jouée pour maximiser mes gains ?

Modélisation :

- chaque machine suit une loi inconnue ν_k d'espérance μ_k ,
- soit μ^* la machine i^* d'espérance maximale,
- soit l_t la machine jouée au coup t , x_{l_t} la v.a. du gain associé,
- regret après n coups : $R_n = n * \mu_{i^*} - \sum_{t=1}^n x_{l_t}$
- minimiser : $\mathbb{E}(R_n) = n\mu^* - \mathbb{E} \sum_{i=1}^K T_i(n)\mu_i$
avec $T_i(n)$ le nombre de fois ou la machine i a été joué durant n coups.

Applications : dilemne de l'exploration/exploitation

Politique de sélection

- ϵ -greedy : jouer avec une certaine probabilité la meilleure machine, au hasard sinon.
- Upper-Confidence Bound : politique optimiste.
 - ▶ Inégalité d'Hoeffding : avec une probabilité au moins $1 - \epsilon$,

$$\mathbb{E}X \leq \frac{1}{m} \sum_{s=1}^m X_s + \sqrt{\frac{\log(\epsilon^{-1})}{2m}}$$

- ▶ UCB :

$$\operatorname{argmax} \mu_i + \sqrt{\frac{2\log(t+1)}{T_i(t)}}$$

Utilisations :

- marketing ciblé/google ads
- approximation de monte-carlo : I.A pour go